## PAPER TITLE

## 0.1. Comparaison RF-GBDT.

Les forêts aléatoires et le *gradient boosting* paraissent très similaires au premier abord: il s'agit de deux approches ensemblistes, qui construisent des modèles très prédictifs performants en combinant un grand nombre d'arbres de décision. Mais en réalité, ces deux approches présentent plusieurs différences fondamentales:

- Les deux approches reposent sur des fondements théoriques différents: la loi des grands nombres pour les forêts aléatoires, la théorie de l'apprentissage statistique pour le boosting.
- Les arbres n'ont pas le même statut dans les deux approches. Dans une forêt aléatoire, les arbres sont entraînés indépendamment les uns des autres et constituent chacun un modèle à part entière, qui peut être utilisé, représenté et interprété isolément. Dans un modèle de boosting, les arbres sont entraînés séquentiellement, ce qui implique que chaque arbre n'a pas de sens indépendamment de l'ensemble des arbres qui l'ont précédé dans l'entraînement.
- Les points d'attention dans l'entraînement ne sont pas les mêmes: arbitrage puissance-corrélation dans la RF, arbitrage puissance-overfitting dans le *boosting*.
- overfitting: borne théorique à l'overfitting dans les RF, contre pas de borne dans le boosting. Deux conséquences: 1/ lutter contre l'overfitting est essentiel dans l'usage du boosting; 2/ le boosting est plus sensible au bruit et aux erreurs sur y que la RF.
- Conditions d'utilisation: la RF peut être utilisée en OOB, pas le boosting.
- Complexité d'usage: peu d'hyperparamètres dans les RF, contre un grand nombre dans le boosting.

## References